

Universidad de Costa Rica

Escuela de Ciencias de la Computación e Informática

CI-0141 Bases de Datos Avanzadas

Especificación de Proyecto

Proyecto Programado 2: Desarrollo de ETL y Visualización de Datos

Fecha de entrega: Lunes 22 de junio de 2026

Peso: 20% de la nota final

1. Información General

Este documento define la especificación del Proyecto Programado 2 del curso CI-0141 Bases de Datos Avanzadas de la Universidad de Costa Rica. El proyecto consiste en el diseño e implementación de un proceso completo de ETL (Extract, Transform, Load) utilizando datos reales de una oficina institucional, culminando en la creación de dashboards y reportes para la toma de decisiones.

Curso	CI-0141 Bases de Datos Avanzadas
Universidad	Universidad de Costa Rica (UCR)
Escuela	Escuela de Ciencias de la Computación e Informática (ECCI)
Proyecto	Proyecto Programado 2 – ETL y Visualización de Datos
Peso	20% de la nota final
Fecha de entrega	Lunes 22 de junio de 2026
Cliente	Oficina institucional a elección del grupo (ver sección 2)

2. Selección del Cliente (Oficina Institucional)

Cada grupo debe seleccionar una oficina institucional como cliente para el proyecto. La oficina debe generar datos en al menos 3 formatos distintos (por ejemplo: CSV, base de datos relacional y API) y estar dispuesta a facilitar acceso a sus datos para fines académicos.

2.1 Ejemplos de oficinas institucionales

A continuación se listan algunos ejemplos de oficinas que podrían servir como cliente. Los grupos no están limitados a estas opciones:

- Red Sismológica Nacional (RSN) UCR-ICE: datos sísmicos y vulcanológicos, catálogos históricos, estaciones de monitoreo, datos en tiempo real.
- Oficina de Registro e Información (ORI) UCR: datos de matrícula, rendimiento académico, oferta de cursos, estadísticas estudiantiles.
- Centro Nacional de Alta Tecnología (CeNAT): datos de investigación, sensores ambientales, información geoespacial.
- Instituto Meteorológico Nacional (IMN): datos climáticos, estaciones meteorológicas, pronósticos, registros históricos.
- Caja Costarricense de Seguro Social (CCSS): datos de atención médica, estadísticas epidemiológicas, indicadores de gestión.

- Municipalidades: permisos de construcción, recaudación tributaria, gestión de servicios públicos, catastro.

2.2 Criterios de selección

- La oficina debe contar con datos en al menos 3 formatos diferentes (requisito del proyecto).
- Los datos deben tener volumen suficiente para justificar un proceso de ETL.
- Debe existir disposición de la oficina para facilitar el acceso a los datos.
- Se valorará la complejidad y riqueza de los datos seleccionados.

2.3 Justificación

Cada grupo debe incluir en su documentación una justificación de por qué eligieron esa oficina institucional, describiendo el valor que un Data Warehouse y los dashboards/ reportes aportarían a la toma de decisiones de dicha oficina.

3. Objetivos del Proyecto

3.1 Objetivo General

Diseñar e implementar un sistema ETL que integre datos de la oficina institucional seleccionada desde múltiples fuentes y formatos, los transforme y cargue en un Data Warehouse, y los presente mediante dashboards interactivos y reportes analíticos.

3.2 Objetivos Específicos

1. Identificar y conectar al menos 3 fuentes de datos en formatos distintos (CSV, base de datos relacional, API REST).
2. Diseñar un modelo dimensional (estrella o copo de nieve) para el Data Warehouse.
3. Implementar pipelines de ETL con procesos de limpieza, validación y transformación de datos.
4. Desarrollar al menos 5 dashboards interactivos para visualización de datos.
5. Crear al menos 5 reportes analíticos con métricas e indicadores clave.
6. Documentar la arquitectura, decisiones técnicas y manual de usuario.

4. Alcance del Proyecto

4.1 Dentro del alcance

- Recolección de datos desde al menos 3 fuentes con formatos diferentes.
- Diseño de arquitectura de datos y modelado dimensional del Data Warehouse.
- Desarrollo de procesos ETL automatizados o semi-automatizados.
- Creación de 5 dashboards interactivos y 5 reportes estáticos/dinámicos.
- Documentación técnica completa del proyecto.
- Validación y control de calidad de los datos procesados.

4.2 Fuera del alcance

- Implementación en producción o despliegue para usuarios finales de la oficina.
- Procesamiento de datos en tiempo real (streaming).
- Desarrollo de modelos predictivos o de machine learning.
- Integración con sistemas operacionales internos de la oficina.

5. Fuentes de Datos

El proyecto debe integrar datos de al menos 3 fuentes con formatos distintos. Los formatos requeridos son: archivos planos (CSV, JSON,), base de datos relacional y al menos una API. A continuación se muestra un ejemplo usando la RSN como referencia:

Formato	Fuente	Descripción
CSV	Catálogo de sismos históricos	Archivos descargables del catálogo sísmico de la RSN con campos: fecha, hora, latitud, longitud, profundidad, magnitud.
Base de Datos	Registros de estaciones sismológicas	Base de datos relacional (PostgreSQL/MySQL) con información de las 175+ estaciones: ubicación, tipo de sensor, estado operativo, registros de mantenimiento.
API REST	Datos en tiempo real / USGS	API de la RSN (rsnapiusr.ucr.ac.cr) o del USGS (earthquake.usgs.gov) para consultar sismos recientes en formato JSON/GeoJSON.

Nota: La tabla anterior es un ejemplo ilustrativo basado en la RSN. Cada grupo debe identificar fuentes equivalentes según la oficina institucional que seleccione.

5.1 Consideraciones sobre los datos

- Los estudiantes deben gestionar el acceso a los datos directamente con la oficina institucional seleccionada.
- Se deben documentar los acuerdos de confidencialidad o restricciones de uso, si aplican.
- Se permite complementar con datos públicos relacionados al dominio si la oficina no puede proporcionar todos los formatos requeridos.
- Se debe documentar el diccionario de datos de cada fuente.

6. Arquitectura del Sistema

6.1 Arquitectura general

El sistema debe seguir una arquitectura de Data Warehouse clásica con las siguientes capas:

1. **Capa de Extracción (Extract):** Conectores a las fuentes de datos (lectores CSV, conectores de BD, clientes HTTP para APIs).
2. **Capa de Transformación (Transform):** Limpieza, validación, normalización, enriquecimiento y conformado de datos.
3. **Capa de Carga (Load):** Inserción de datos transformados en el modelo dimensional del Data Warehouse.
4. **Capa de Presentación:** Dashboards interactivos y reportes conectados al Data Warehouse.

6.2 Modelo dimensional

Se debe diseñar un modelo dimensional (esquema estrella o copo de nieve) adecuado al dominio de la oficina seleccionada. El modelo debe incluir al menos:

- Una o más tablas de hechos con las métricas principales del dominio.
- Dimensión Tiempo: Año, mes, día, hora, día de la semana (obligatoria).
- Al menos 3 dimensiones adicionales relevantes al dominio (ej: ubicación, categoría, entidad, estado).
- Claves subrogadas en todas las dimensiones.
- Ejemplo RSN: Hechos = eventos sísmicos; Dimensiones = tiempo, ubicación, estación, clasificación de magnitud.

6.3 Selección de herramientas

Los estudiantes deben seleccionar las herramientas tecnológicas basados en las necesidades del cliente y la infraestructura disponible. Se debe justificar la elección en la documentación. Algunas opciones incluyen:

- ETL: Python (pandas, SQLAlchemy), Pentaho Data Integration, Apache NiFi, Talend, SSIS.
- Base de datos / DW: PostgreSQL, MySQL, SQL Server, Snowflake.
- Visualización: Power BI, Tableau, Apache Superset, Metabase, Grafana.
- Orquestación (opcional): Apache Airflow, Prefect, Luigi.

7. Especificación del Proceso ETL

7.1 Extracción

- Implementar conectores específicos para cada formato de fuente (CSV parser, DB connector, HTTP client).
- Manejar paginación en APIs y archivos grandes.
- Registrar metadatos de cada extracción: timestamp, cantidad de registros, estado.
- Implementar manejo de errores y reintentos.

7.2 Transformación

- Limpieza: eliminación de duplicados, manejo de valores nulos, corrección de formatos.
- Validación: reglas de negocio específicas del dominio (ej: rangos válidos, consistencia entre campos, integridad de relaciones).
- Normalización: unificación de formatos de fecha/hora, codificaciones, unidades de medida y nomenclaturas entre fuentes.
- Enriquecimiento: derivación de campos calculados, clasificaciones automáticas, agregaciones relevantes al dominio.
- Conformado: mapeo a dimensiones del modelo estrella, generación de claves subrogadas.

7.3 Carga

- Estrategia de carga inicial (full load) y cargas incrementales.
- Manejo de Slowly Changing Dimensions (SCD) según corresponda.
- Validación post-carga: conteos, sumas de control, integridad referencial.
- Registro de auditoría: qué se cargó, cuándo, cuántos registros.

8. Dashboards (mínimo 5)

Cada dashboard debe ser interactivo, con filtros dinámicos y visualizaciones claras. Los dashboards deben ser relevantes al dominio de la oficina seleccionada. A continuación se muestra un ejemplo basado en la RSN como referencia:

#	Dashboard	Descripción
1	Mapa de Actividad Sísmica	Mapa interactivo de Costa Rica con epicentros geolocalizados, filtrable por magnitud, profundidad y rango de fechas.
2	Tendencias Temporales	Gráficos de línea y barras mostrando frecuencia sísmica por mes/año, con líneas de tendencia y promedios móviles.
3	Distribución por Magnitud y Profundidad	Histogramas y scatter plots de magnitud vs. profundidad, con segmentación por zona geográfica.

4	Monitor de Actividad Volcánica	Panel con estado de los volcanes activos, conteo de eventos asociados, nivel de alerta y última actividad registrada.
5	KPIs y Resumen Ejecutivo	Indicadores clave: total de sismos del periodo, magnitud máxima, promedio de profundidad, comparación con periodo anterior.

8.1 Requisitos generales de dashboards

- Cada dashboard debe incluir al menos 3 visualizaciones diferentes (gráficos, mapas, tablas, KPIs).
- Deben contar con filtros interactivos (por fecha, magnitud, región, etc.).
- Diseño responsivo y con paleta de colores consistente.
- Títulos descriptivos y etiquetas claras en ejes y leyendas.

9. Reportes (mínimo 5)

Los reportes deben ser documentos estructurados que presenten análisis detallados. Pueden ser estáticos (PDF/Word) o dinámicos (generados bajo demanda desde la herramienta de BI). Los reportes deben ser relevantes al dominio de la oficina seleccionada. Ejemplo basado en la RSN:

#	Reporte	Descripción
1	Reporte Mensual de Sismicidad	Resumen estadístico mensual: cantidad de sismos, magnitud promedio/máxima, distribución geográfica, comparación con meses anteriores.
2	Análisis por Zona Geográfica	Desglose de actividad sísmica por provincia/región, con ranking de zonas más activas y mapas de calor.
3	Reporte de Eventos Significativos	Detalle de sismos con magnitud ≥ 4.0 : ubicación, profundidad, intensidad percibida, poblaciones afectadas.
4	Correlación Sísmica-Volcánica	Análisis cruzado entre actividad sísmica y volcánica, patrones temporales y espaciales de correlación.
5	Reporte de Calidad de Datos	Métricas de completitud, consistencia y validez de las fuentes de datos: registros procesados, descartados, duplicados y anomalías detectadas.

9.1 Requisitos generales de reportes

- Cada reporte debe incluir: título, fecha de generación, periodo analizado, fuentes de datos utilizadas.
- Incluir tanto visualizaciones como tablas de datos de respaldo.
- Agregar interpretaciones textuales de los hallazgos principales.
- Los reportes deben poder generarse para diferentes periodos de tiempo.

10. Cronograma

El siguiente cronograma sugiere la distribución de actividades para las 3 semanas disponibles antes de la fecha de entrega:

Fase	Actividad	Periodo	Detalle
Fase 1	Análisis y recolección de datos	Semana 1 (2–8 jun)	Contactar oficina institucional, identificar fuentes, obtener acceso a datos
Fase 2	Diseño de arquitectura	Semana 1–2 (5–12 jun)	Modelado dimensional, diseño del Data Warehouse
Fase 3	Desarrollo del ETL	Semana 2–3 (9–18 jun)	Implementar extracción, transformación y carga
Fase 4	Dashboards y reportes	Semana 3 (15–20 jun)	Crear al menos 5 dashboards y 5 reportes
Fase 5	Pruebas y documentación	Semana 3–4 (18–22 jun)	Validación de datos, documentación técnica
Entrega	Entrega final	Lunes 22 jun	Entrega de todos los artefactos

11. Entregables

1. **Código fuente:** Repositorio con todo el código del ETL, scripts de creación de la BD y archivos de configuración.
2. **Data Warehouse:** Base de datos poblada con los datos transformados, incluyendo scripts DDL.
3. **Dashboards:** Mínimo 5 dashboards funcionales e interactivos.
4. **Reportes:** Mínimo 5 reportes analíticos generados desde el DW.
5. **Documentación técnica:** Arquitectura del sistema, modelo dimensional, diccionario de datos, decisiones de diseño, manual de ejecución.
6. **Presentación:** Presentación oral del proyecto (si el profesor lo requiere).

12. Rúbrica de Evaluación

La evaluación del proyecto se distribuirá de la siguiente manera:

Criterio	Peso
Fuentes de datos (3+ formatos)	15%
Diseño de arquitectura y Data Warehouse	20%
Desarrollo del ETL (calidad, documentación)	25%
Dashboards (mínimo 5)	15%
Reportes (mínimo 5)	15%
Documentación y presentación	10%

13. Consideraciones Adicionales

- El trabajo es grupal. Todos los miembros deben contribuir de forma equitativa y documentar su participación.
- Se valorará la justificación de las herramientas seleccionadas con base en las necesidades del cliente y la infraestructura disponible.
- Los datos sensibles o confidenciales deben tratarse conforme a los acuerdos establecidos con la oficina institucional.
- Se recomienda utilizar control de versiones (Git) para el código fuente y la documentación.
- Las entregas tardías estarán sujetas a las políticas del curso.

- Se espera que los estudiantes demuestren comprensión de los conceptos de Data Warehousing y ETL vistos en clase.